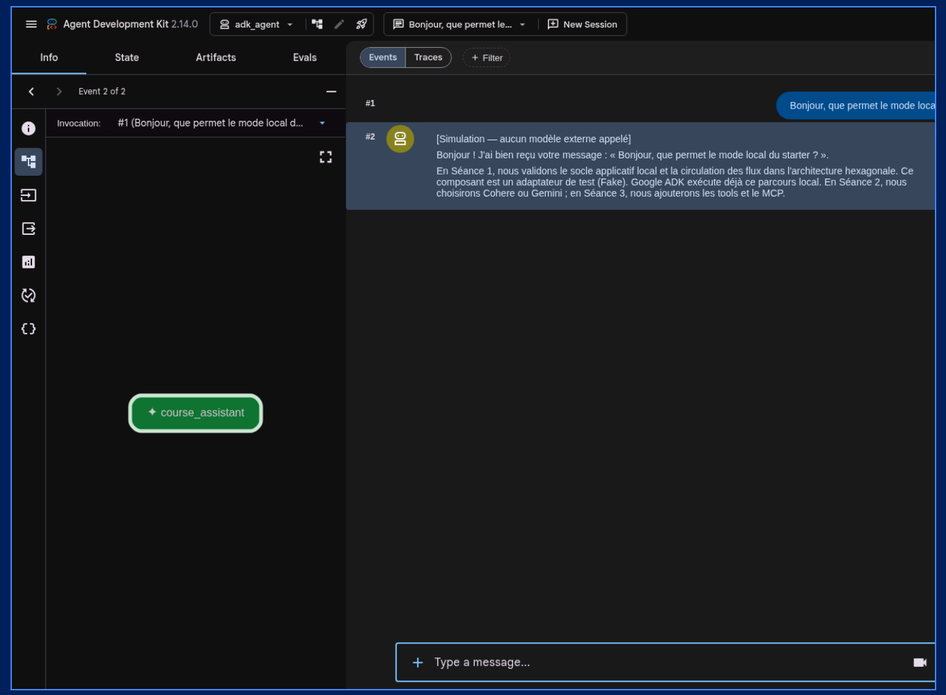
MISSION DE LA SÉANCE

Brancher l’IA. Garder le contrôle.

Un LLM derrière un port, puis un premier RAG capable de citer ses preuves et de s’abstenir.



LA CIBLE

À la fin, votre assistant sait répondre… ou dire qu’il ne sait pas.

LLM

Interchangeable

Fake et fournisseur live respectent le même contrat.

RAG

Sourcé

Chaque réponse montre le passage réellement récupéré.

TESTS

Sans réseau

Les scénarios automatiques restent déterministes.

20 MINUTES MAXIMUM

Préparez un corpus petit, propre et explicable.

1

Choisir 3 à 8 documents

Markdown ou texte, publics ou synthétiques, liés à votre domaine.

2

Donner des IDs stables

Une source doit rester identifiable après réindexation.

3

Écrire 4 questions

Deux répondables, une ambiguë et une hors corpus.

Bloqué sur les données ?

Utilisez temporairement `tp/fixtures/music-library/corpus/`. Ce jeu sert de secours, pas de sujet imposé.

```
uv sync --extra rag --group dev
```

LE RUNTIME EST FOURNI

Utilisez ADK derrière le port fourni.



- ✓ Repérer TextGeneratorPort et son adaptateur ADK.
- ✓ Configurer Cohere ou Gemini dans .env.
- ✓ Échouer clairement si la config est inconnue.
- ✓ Tester le contrat avec le fake.

S2 · UTILISATION GUIDÉE

Deux fournisseurs. Le même parcours fourni.

Cohere

```
FILROUGE_LLM_PROVIDER=cohere
COHERE_MODEL=command-a-03-2025
COHERE_API_KEY=…
```

Gemini

```
FILROUGE_LLM_PROVIDER=gemini
GEMINI_MODEL=gemini-2.5-flash
GOOGLE_API_KEY=…
```

Choisir un profil dans votre .env local, puis redémarrer Streamlit. Le profil fake reste disponible sans clé, avec une simulation explicite.

```
uv run adk web . --host 127.0.0.1 --port 8001
```

Choisir adk_agent pour observer le parcours. Les concepts ADK seront étudiés en S3. Le backend d’embedding reste un choix distinct.

USE CASE INGEST

Transformez les documents en preuves recherchables.



01

Idempotence

Réindexer la même version ne crée pas de doublon.

02

Traçabilité

Chaque chunk garde son document, sa position et sa version.

03

Compatibilité

Un changement de modèle exige une réindexation explicite.

USE CASE ASKWITHRAG

Recherchez d’abord. Générez ensuite.

1

Valider la question

Taille, vide, caractères et contexte autorisé.

2

Récupérer 1 à 3 passages

Seuil minimal et nombre de sources bornés.

3

Construire le prompt

Question + passages numérotés + consigne de citation.

La règle d’abstention

Si aucun passage ne dépasse le seuil, ne pas appeler le LLM. Retourner une réponse explicite avec zéro source.

« Je ne dispose pas de preuve suffisante dans le corpus. »

CAPSULE C4 · SRP

Une fonction pure pour la salutation. Rien de plus.

À extraire

`build_greeting(name, language)` construit le texte. Streamlit lit les champs et affiche le résultat.

- aucun import Streamlit dans la fonction ;
- langues supportées testées ;
- entrée invalide explicite.

```
uv run pytest
uv run ruff check .
```

- ✓ Fake et live ont le même contrat.
- ✓ Aucun test n’appelle le réseau.
- ✓ La salutation est testée directement.

MONTREZ, NE RACONTEZ PAS

Votre démonstration tient en quatre questions.

01

Réponse directe

Une information présente dans un seul document.

02

Deux sources

Une réponse qui oblige à montrer deux passages.

03–04

Limite

Une question ambiguë puis une question hors corpus.

```
git add .
git commit -m "Ajoute le LLM derrière un port et le premier RAG"
```

AVANT DE QUITTER S2

Votre système est remplaçable, sourcé et testable.

Vous avez construit

- un port LLM et plusieurs adaptateurs ;
- une ingestion idempotente ;
- un RAG avec citations ;
- une abstention explicite.

À conserver pour S3

- le fake pour les tests ;
- les quatre questions de référence ;
- les IDs et versions du corpus ;
- les erreurs de configuration visibles.

```
uv run pytest  &&  uv run ruff check .
```